Predição da Qualidade de Vinhos: Uma Abordagem via Regressão Penalizada, Mínimos Quadrados Parciais e Redes Neurais

João Otávio Brasil Nascimento
Engenharia de Computação (563537)
Universidade Federal do Ceará (UFC)
Fortaleza, CE, Brasil
otavio.brasil@alu.ufc.br

Iuri Fernandes Bastos
Engenharia de Computação (563536)
Universidade Federal do Ceará (UFC)
Fortaleza, CE, Brasil
iuriferbastos@alu.ufc.br

Jonas Albuquerque Araújo
Engenharia de Computação (404213)
Universidade Federal do Ceará (UFC)
Fortaleza, CE, Brasil
jonasalbuquerque@alu.ufc.br

Danilo Bezerra Vieira
Engenharia de Computação (554767)
Universidade Federal do Ceará (UFC)
Fortaleza, CE, Brasil
danilovieira@alu.ufc.br

***Resumo*—Este trabalho apresenta uma análise comparativa de modelos preditivos estatísticos e de aprendizado de máquina aplicados à estimativa da qualidade de vinhos tintos e brancos com base em atributos físico-químicos. O estudo aborda a implementação analítica rigorosa (from scratch) de modelos de Regressão Linear (OLS) e Regressão Penalizada Lasso (L_1) via descida por coordenadas, validando os resultados com bibliotecas consagradas. Adicionalmente, explora técnicas de redução de dimensionalidade supervisionada através de Mínimos Quadrados Parciais (PLS) e avalia o limite de modelagem não-linear utilizando Redes Neurais Artificiais (MLP). Os modelos tiveram os seus hiperparâmetros otimizados via validação cruzada K-Fold e foram comparados num conjunto de teste isolado através da Raiz do Erro Quadrático Médio (RMSE) e do Coeficiente de Determinação (R^2), evidenciando os impactos da regularização e da complexidade arquitetural no desempenho preditivo.**

***Index Terms*—Regressão Linear Múltipla, Seleção de Atributos, Perceptron Multicamada, Predição de Qualidade de Vinhos**

I. Introdução

A qualidade do vinho tem sido tradicionalmente avaliada por meio de degustação sensorial realizada por especialistas humanos, um processo que se revela inerentemente subjetivo, demorado e custoso. A percepção sensorial do vinho constitui um fenômeno multidimensional complexo, resultante da integração de múltiplos estímulos fisiológicos, cognitivos e contextuais do avaliador [1]. Em contrapartida, as propriedades físico-químicas da bebida — como níveis de acidez, açúcar e álcool — podem ser extraídas objetivamente através de testes laboratoriais de rotina. Diante desse cenário, a modelagem preditiva busca responder se é possível prever a qualidade sensorial atribuída a um vinho a partir exclusivamente das suas características químicas objetivas.

Para investigar e modelar essa relação, este estudo utiliza a base de dados pública de vinhos tintos e brancos do tipo Vinho Verde, produzidos em Portugal. O conjunto de dados é composto por $D = 11$ variáveis preditoras contínuas e uma variável de saída ordinal que representa a percepção sensorial da qualidade, aferida em uma escala de 0 a 10 por especialistas. Os preditores físico-químicos contemplados na base são:

- **Fixed acidity (Acidez fixa):** Refere-se aos ácidos orgânicos não voláteis (como tartárico e málico) responsáveis pelo frescor e retenção da acidez natural.
- **Volatile acidity (Acidez volátil):** Representa o teor de ácidos gasosos, fundamentalmente o ácido acético; em níveis elevados, confere odor de vinagre e possui forte correlação negativa com a qualidade.
- **Citric acid (Ácido cítrico):** Ácido presente em pequenas quantidades que confere frescor aromático cítrico ao vinho.
- **Residual sugar (Açúcar residual):** Concentração de glicose e frutose que permanece após a fermentação, definindo a doçura e influenciando o corpo da bebida.
- **Chlorides (Cloretos):** Teor de cloreto de sódio que reflete a salinidade mineral proveniente do solo ou da água de irrigação.
- **Free sulfur dioxide (Dióxido de enxofre livre):** Forma ativa de SO_2 que atua de maneira essencial como agente antioxidante e antimicrobiano.
- **Total sulfur dioxide (Dióxido de enxofre total):** Soma do SO_2 livre e das frações combinadas; em concentrações excessivas, causa sensação sufocante e afeta negativamente o paladar.
- **Density (Densidade):** Massa específica do líquido, que depende estritamente do balanço entre o teor alcoólico e os açúcares solúveis.
- **pH:** Potencial hidrogeniônico, geralmente situado entre 2,9 e 4,0, que condiciona a estabilidade microbiológica e

a cor.

- **Sulphates (Sulfatos):** Aditivos que atuam como suplemento enzimático e promotores da eficácia antioxidante.
- **Alcohol (Álcool):** Teor alcoólico volumétrico, destacando-se como um dos preditores com maior correlação positiva linear com a nota final de qualidade.

A **Seção II (Métodos)** sintetiza a estratégia de modelagem, englobando o pré-processamento dos dados (transformações logarítmicas e padronização) e o ajuste de quatro modelos preditivos: Regressão Linear (OLS) e Lasso (L_1) desenvolvidas analiticamente (*from scratch*), Mínimos Quadrados Parciais (PLS) e Redes Neurais Artificiais (MLP), com hiperparâmetros calibrados via *5-Fold Cross-Validation*. Cumpre ressaltar que todos os passos, otimizações e validações detalhados ao longo desta etapa para o vinho tinto foram aplicados de forma idêntica à base de dados do vinho branco. O desempenho consolidado de todos os algoritmos aplicados a ambos os cenários é reportado na **Seção III (Resultados)** e interpretado na **Seção IV (Discussão)**.

A **Seção III (Resultados)** reporta a avaliação preditiva definitiva dos modelos aplicados ao conjunto de teste inédito. O desempenho de cada algoritmo é apresentado e comparado quantitativamente de forma emparelhada por meio da Raiz do Erro Quadrático Médio (RMSE) e do Coeficiente de Determinação (R^2).

Por fim, a **Seção IV (Discussão)** interpreta as métricas obtidas, debatendo o ganho prático da redução de dimensionalidade supervisionada (PLS) e a eficácia da regularização e seleção de atributos do modelo Lasso à luz do princípio estatístico da parcimônia. Fundamentalmente, a seção avalia o baixo desempenho da modelagem não-linear baseada em redes neurais (MLP) frente às regressões lineares, delineando a verdadeira natureza da relação empírica entre as propriedades químicas em nível laboratorial e a complexa percepção do paladar humano.

II. Métodos

A. Pré-processamento e Análise Exploratória

A base de dados utilizada é composta por duas amostras independentes: vinho tinto, com $N = 1599$ observações, e vinho branco, com $N = 4898$ observações, ambas descritas por $D = 11$ variáveis preditoras contínuas. A avaliação exploratória inicial revelou que diversos preditores apresentavam uma forte assimetria positiva (cauda longa à direita). Para estabilizar a variância e mitigar o impacto de valores extremos (*outliers*), aplicou-se uma transformação logarítmica da forma $x' = \ln(1 + x)$ em todas as variáveis que apresentaram coeficiente de assimetria amostral acentuado ($|\gamma| > 0{,}75$).

Após essa correção, calculou-se a matriz de correlação de Pearson para avaliar as relações lineares entre os preditores transformados. A inspeção da matriz confirmou associações físico-químicas esperadas, como a forte correlação positiva entre densidade e açúcar residual no vinho branco e a correlação negativa entre pH e acidez fixa no vinho tinto, conforme ilustrado visualmente pelos mapas de calor na Figura 1.

Cumpre destacar que a análise exploratória exaustiva da base de dados — incluindo a estimação da tabela completa de correlações preditor-saída para as 11 variáveis e a geração dos respectivos gráficos de dispersão (*scatterplots*). Por conseguinte, o escopo desta seção foca-se estritamente nas transformações e associações de maior impacto para a fundamentação da modelagem subsequente.

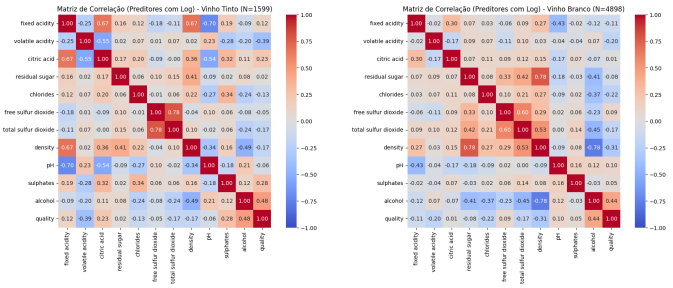


Figura 1. Mapas de calor das matrizes de correlação de Pearson para os vinhos tinto e branco após transformação logarítmica dos preditores.

B. Divisão dos Dados e Construção das Matrizes de Design

Para garantir a capacidade de generalização dos modelos preditivos, o conjunto de dados foi particionado utilizando o método *hold-out* com uma proporção de 70% para treinamento e 30% para teste, mantendo uma semente pseudoaleatória fixa para reprodutibilidade. As partições resultaram nas seguintes quantidades de amostras:

- **Vinho Tinto:** 1119 amostras no conjunto de treino e 480 amostras no conjunto de teste.
- **Vinho Branco:** 3428 amostras no conjunto de treino e 1470 amostras no conjunto de teste.

Para a formulação algébrica da regressão, as variáveis foram organizadas em matrizes de *design* (X) e vetores de resposta (Y). Uma coluna unitária foi concatenada à esquerda da matriz de preditores para acomodar o termo de intercepto (β_0), elevando a dimensão dos atributos para $D + 1 = 12$. Consequentemente, as matrizes de treinamento assumiram as seguintes dimensões:

- **Vinho Tinto:** $X_{\text{train}} \in \mathbb{R}^{1119\times 12}$ e $Y_{\text{train}} \in \mathbb{R}^{1119\times 1}$.
- **Vinho Branco:** $X_{\text{train}} \in \mathbb{R}^{3428\times 12}$ e $Y_{\text{train}} \in \mathbb{R}^{3428\times 1}$.

C. Regressão Linear Múltipla (OLS) From Scratch

O primeiro modelo construído foi a Regressão Linear Simples via Mínimos Quadrados Ordinários (OLS). A implementação foi realizada de forma puramente analítica (*from scratch*), sem o uso de otimizadores embutidos de bibliotecas de *machine learning*. O vetor de coeficientes ótimos $\hat{\beta}$ foi obtido pela solução direta das equações normais:

$$\hat{\beta} = (X^T X)^{-1} X^T Y \tag{1}$$

Em termos computacionais, a lógica da função consistiu em calcular a transposta da matriz de *design* (X^T), efetuar a multiplicação matricial para obter a matriz de covariância não centralizada ($X^T X$), calcular sua inversa e, por fim, multiplicar pelo vetor projetado $X^T Y$.

Os coeficientes OLS estimados ($\hat{\beta}$) para os 11 preditores e o intercepto, ajustados sobre os dados transformados de treinamento de ambos os tipos de vinho, estão sumarizados na Tabela I.

Tabela I
COEFICIENTES ESTIMADOS VIA OLS (*Beta Hat*) PARA VINHOS TINTO E BRANCO

Preditor	Beta Tinto	Beta Branco
intercept	37.358983	47.832478
fixed acidity	0.607202	-0.013818
volatile acidity	-1.105802	-2.472894
citric acid	-0.358115	-0.052665
residual sugar	0.110809	0.245423
chlorides	-1.769807	-0.362238
free sulfur dioxide	0.105697	0.335218
total sulfur dioxide	-0.153211	-0.002010
density	-40.429776	-68.252033
pH	-0.104113	0.278353
sulphates	1.690853	0.909510
alcohol	3.163988	0.314644

D. Avaliação Preditiva e Validação da Implementação Analítica

Para aferir a capacidade de generalização do modelo OLS construído, o desempenho preditivo foi medido rigorosamente no conjunto de teste isolado (representando 30% da amostra original), garantindo que o modelo fosse avaliado sobre dados não observados durante a etapa de treinamento. Adicionalmente, implementou-se manualmente (*from scratch*) uma rotina de validação cruzada estruturada em 5 dobras (*5-Fold Cross-Validation*) exclusiva sobre a partição de treino, desenvolvida de forma analítica sem o uso de bibliotecas de terceiros. Esta técnica de reamostragem estatística particiona os dados de treino em cinco subconjuntos mutuamente exclusivos; em cada iteração, o modelo é ajustado em quatro dobras e testado na dobra retida. O processo assegura uma estimativa não viesada do erro preditivo, mitigando flutuações amostrais decorrentes de uma única divisão de dados. Com o objetivo de validar a corretude matemática da implementação analítica desenvolvida (*scratch*), os resultados foram contrastados com uma abordagem *built-in* de alto padrão. Para tanto, instanciou-se o regressor `LinearRegression` oriundo da biblioteca `scikit-learn`, um dos ecossistemas mais robustos de *machine learning* em Python. Os coeficientes angulares e o intercepto extraídos de ambas as abordagens para os dados do vinho tinto estão mapeados na Tabela II.

A inspeção da tabela revela que os coeficientes calculados analiticamente a partir das equações normais coincidem com as estimativas internas do `scikit-learn` até a oitava casa decimal. O resíduo mapeado na coluna *Diferença Absoluta* circunda a ordem de grandeza de 10^{-9} a 10^{-13}, derivando estritamente de ruídos de precisão de ponto flutuante durante as rotinas de inversão de matrizes no processador algébrico.

Esta equivalência perfeita também é corroborada graficamente pela Figura 2, que dispõe os coeficientes de regressão de forma emparelhada. O gráfico de barras atesta o sobreposição exata e simétrica da magnitude de todos os *betas*. Nota-se, do ponto de vista do impacto físico-químico, que a variável *density* detém, de forma proeminente, a maior magnitude (negativa) nos coeficientes brutos, exigindo cautela na sua interpretação dado o problema inerente de diferença de escalas antes da padronização estatística abordada nas etapas seguintes.

Tabela II
COMPARAÇÃO DE COEFICIENTES OLS (VINHO TINTO): IMPLEMENTAÇÃO ANALÍTICA VS. `SCIKIT-LEARN`

Preditor	Beta Scratch	Beta Built-in	Diferença Absoluta
intercept	37.358983	37.358983	4.05×10^{-9}
fixed acidity	0.607202	0.607202	9.20×10^{-12}
volatile acidity	-1.105802	-1.105802	2.53×10^{-12}
citric acid	-0.358115	-0.358115	9.03×10^{-12}
residual sugar	0.110809	0.110809	2.49×10^{-12}
chlorides	-1.769807	-1.769807	1.15×10^{-11}
free sulfur dioxide	0.105697	0.105697	6.65×10^{-13}
total sulfur dioxide	-0.153211	-0.153211	1.76×10^{-13}
density	-40.429776	-40.429776	2.39×10^{-9}
pH	-0.104113	-0.104113	6.88×10^{-12}
sulphates	1.690853	1.690853	3.22×10^{-12}
alcohol	3.163988	3.163988	1.03×10^{-11}

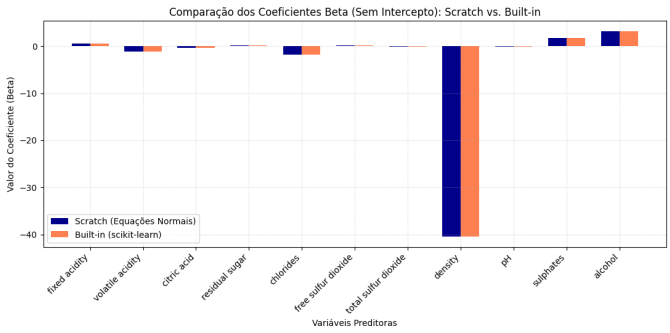


Figura 2. Emparelhamento gráfico dos coeficientes de regressão (excluindo intercepto) obtidos via equações normais (Scratch) e biblioteca padrão (Built-in).

Cumpre ressaltar que o mesmo procedimento de validação cruzada e comparação com a biblioteca base foi replicado para o conjunto de dados do vinho branco, atestando idêntica convergência entre a formulação analítica e a estimativa do modelo *built-in*, com divergências absolutas limitadas à mesma ordem de grandeza (10^{-11}).

E. Regressão Penalizada Lasso (L_1) e Otimização via Descida por Coordenadas

Para mitigar a variância do estimador OLS e introduzir seleção automática de atributos (*sparsity*), aplicou-se a técnica Lasso (*Least Absolute Shrinkage and Selection Operator*). Devido à sensibilidade da penalidade ℓ_1 à escala das variáveis, todos os preditores foram previamente padronizados via Z-score ($z_{ij} = (x_{ij} - \bar{x}_j)/s_j$), estimando-se a média ($\bar{x}_j$) e o desvio padrão (s_j) estritamente na partição de treino para evitar vazamento de dados (*data leakage*).

A função de perda do Lasso adiciona uma restrição ℓ_1 à soma dos resíduos quadráticos (excluindo-se o intercepto β_0 da penalização):

$$\min_{\beta_0,\,\beta}\left\{\frac{1}{2N}\sum_{i=1}^{N}\left(y_i-\beta_0-\sum_{j=1}^{D}z_{ij}\beta_j\right)^2+\lambda\sum_{j=1}^{D}|\beta_j|\right\} \quad (2)$$

Com os dados centralizados ($\bar{z}_j = 0$), o intercepto converge para a média incondicional $\hat{\beta}_0 = \bar{y}$. A não-diferenciabilidade da norma ℓ_1 em zero inviabiliza soluções diretas em forma fechada, mas promove a anulação exata de coeficientes redundantes.

O algoritmo foi implementado manualmente (*from scratch*) utilizando o método de **Descida por Coordenadas** (*Coordinate Descent*). A lógica por trás dessa abordagem é bastante intuitiva: o modelo ajusta o peso de um atributo por vez, enquanto mantém todos os outros congelados. Durante esse ciclo iterativo, o algoritmo aplica uma regra conhecida como limiarização suave (*soft-thresholding*). Em termos práticos, essa regra funciona como um filtro que encolhe gradativamente os coeficientes em direção a zero, eliminando por completo o peso daquelas variáveis que não contribuem de forma significativa para o resultado.

O impacto prático dessa seleção automática de atributos fica evidente na Tabela III. Ao aplicarmos uma intensidade de penalização $\alpha = 0{,}05$ (resultando em um intercepto $\hat{\beta}_0 = 5{,}621984$), o modelo conseguiu descartar e zerar exatamente 6 dos 11 atributos originais. Com isso, a regressão filtrou as redundâncias e reteve em sua equação final apenas as variáveis mais importantes e discriminativas.

Tabela III
COEFICIENTES ESTIMADOS VIA LASSO ($\lambda = 0{,}05$) PARA VINHO TINTO

Preditor	Beta Lasso
fixed acidity	0.000000
volatile acidity	-0.171773
citric acid	0.000000
residual sugar	0.000000
chlorides	-0.011755
free sulfur dioxide	0.000000
total sulfur dioxide	-0.016816
density	0.000000
pH	0.000000
sulphates	0.087167
alcohol	0.296236

1) Seleção do Hiperparâmetro Ótimo via Validação Cruzada ($K = 5$): A intensidade da regularização λ foi calibrada exclusivamente na base de treinamento mediante validação cruzada em 5 dobras (*5-Fold Cross-Validation*), avaliando uma grade logarítmica de 15 valores no intervalo $[10^{-4}, 10^{0}]$. A Figura 3 sumariza o perfil de desempenho ao longo da busca.

Como evidenciado na Figura 3, o modelo atinge o seu erro mínimo de validação em $\lambda^* = 0{,}00518$ ($10^{-2{,}29}$), com RMSE $= 0{,}6606 \pm 0{,}0292$ e $R^2 = 0{,}3292 \pm 0{,}0702$. Esse valor define o compromisso ótimo entre viés e variância: penalidades inferiores preservam complexidade desnecessária com desempenho equivalente, enquanto valores superiores

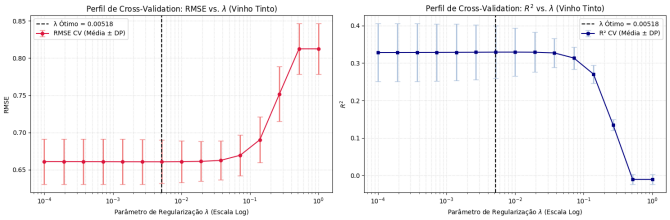


Figura 3. Perfil de validação cruzada ($K = 5$) do Lasso (Vinho Tinto): RMSE (esquerda) e R^2 (direita) em função de λ com indicação do ponto ótimo ($\lambda^* = 0{,}00518$).

a 10^{-2} conduzem a um subajuste (*underfitting*) acelerado, culminando na anulação de todos os preditores ($\lambda \geq 0{,}518$), onde o modelo colapsa para a predição trivial da média ($\hat{y} = \bar{y}$, RMSE $\approx 0{,}8124$).

2) Validação com a Biblioteca Padrão (Built-in): Para assegurar a precisão numérica da rotina de descida por coordenadas desenvolvida analiticamente, o modelo final foi ajustado utilizando o parâmetro ótimo ($\lambda^* = 0{,}00518$) e comparado diretamente com a classe `Lasso` da biblioteca `scikit-learn`. A Tabela IV apresenta os coeficientes obtidos por ambas as implementações (Vinho tinto).

Tabela IV
COMPARAÇÃO DOS COEFICIENTES LASSO ($\lambda^* = 0{,}00518$): IMPLEMENTAÇÃO ANALÍTICA (*Scratch*) VS. SCIKIT-LEARN (*Built-in*)

Preditor	Beta Scratch	Beta Built-in
fixed acidity	0.06020	0.06015
volatile acidity	-0.19347	-0.19347
citric acid	-0.04484	-0.04483
residual sugar	0.00705	0.00703
chlorides	-0.06654	-0.06655
free sulfur dioxide	0.04630	0.04630
total sulfur dioxide	-0.08722	-0.08722
density	-0.03352	-0.03348
pH	-0.02341	-0.02344
sulphates	0.14767	0.14767
alcohol	0.30142	0.30144

A paridade quase exata entre as estimativas confirma a corretude do algoritmo implementado, com discrepâncias residuais na ordem de 10^{-5} decorrentes unicamente dos critérios de tolerância e parada estipulados para a convergência numérica.

F. Mínimos Quadrados Parciais (PLS)

Como alternativa linear baseada na redução de dimensionalidade, explorou-se a técnica de *Partial Least Squares* (PLS), também denominada mínimos quadrados parciais. Diferentemente de outros métodos que realizam a compressão dos preditores de forma cega em relação à variável de saída, o PLS é uma técnica de projeção supervisionada. Ele busca encontrar direções no espaço de características (variáveis latentes ou componentes) que maximizem simultaneamente a variância dos preditores (X) e a covariância com a variável de desfecho ordinal (Y).

1) Seleção do Número de Componentes via Validação Cruzada: Para calibrar a complexidade do modelo e mitigar o risco de sobreajuste (*overfitting*), realizou-se um processo de

validação cruzada estruturada em 5 dobras (*5-Fold Cross-Validation*) exclusiva sobre a partição de treinamento, o qual avaliou de 1 a 11 componentes. Os resultados desse perfilamento encontram-se sumarizados na Tabela V.

Tabela V
RESULTADOS DA VALIDAÇÃO CRUZADA ($K = 5$) PARA O PLS (VINHO TINTO)

Componentes	RMSE Média	RMSE Desv.	R^2 Média	R^2 Desv.
1	0.666965	0.024779	0.316626	0.060876
2	0.661318	0.026202	0.328411	0.057687
3	0.660876	0.030631	0.328257	0.075361
4	0.660438	0.032292	0.329050	0.077876
5	**0.659340**	**0.031807**	**0.331227**	**0.078106**
6	0.659400	0.029862	0.331317	0.073863
7	0.659640	0.030058	0.330828	0.074085
8	0.660227	0.030573	0.329534	0.075864
9	0.660486	0.030706	0.328984	0.076330
10	0.660506	0.030622	0.328947	0.076222
11	0.660489	0.030494	0.328990	0.075997

A evolução do erro médio de validação e do coeficiente de determinação em função do número de variáveis latentes utilizadas é apresentada graficamente na Figura 4.

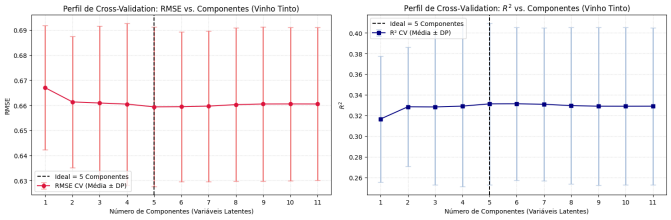


Figura 4. Perfil de validação cruzada ($K = 5$) do modelo PLS para o vinho tinto: RMSE (esquerda) e R^2 (direita) em função do número de componentes. A linha tracejada vertical destaca o valor ótimo identificado (5 componentes).

A inspeção do perfil de validação na Figura 4 evidencia que a inclusão de apenas um componente já provê um desempenho comparável aos modelos anteriores (RMSE $\approx 0{,}667$), o que sinaliza que boa parte da variabilidade do paladar pode ser reduzida a uma única dimensão dominante.

O menor valor de erro preditivo médio é atingido no ponto com exatamente **5 componentes**, alcançando RMSE $= 0{,}6593 \pm 0{,}0318$ e $R^2 = 0{,}3312 \pm 0{,}0781$. A partir do 6º componente, o desempenho estabiliza-se e exibe discreta degradação marginal. A capacidade do modelo de se aproximar assintoticamente da precisão da regressão irrestrita (que utiliza as 11 variáveis), porém retendo menos de metade das dimensões, ilustra a alta eficiência do PLS em concentrar o sinal de interesse e atenuar componentes estocásticos ruidosos nos dados físico-químicos.

G. Modelagem Não-Linear com Redes Neurais Artificiais (MLP)

Para investigar a existência de relações não-lineares complexas e interações de ordem superior entre os atributos químicos e a avaliação sensorial, implementou-se um regressor baseado em *Multi-Layer Perceptron* (MLP).

A arquitetura selecionada é composta por uma camada de entrada com as $D = 11$ variáveis padronizadas (Z-score), duas camadas ocultas totalmente conectadas contendo 50 neurônios cada com funções de ativação não-linear ReLU ($\mathrm{ReLU}(z) = \max(0, z)$), e um único neurônio de saída linear para a estimativa contínua da nota de qualidade. A estrutura do fluxo de informação é sintetizada no diagrama a seguir:

$$\boxed{\text{Entrada: } D = 11} \longrightarrow \boxed{\text{Oculta 1: 50 (ReLU)}} \longrightarrow \boxed{\text{Oculta 2: 50 (ReLU)}} \longrightarrow \boxed{\text{Saída: 1 (Linear)}}$$

O treinamento foi conduzido com o algoritmo de otimização Adam por até 2000 épocas, utilizando parada antecipada (*early stopping*) com partição interna de validação para conter o sobreajuste aos dados ruidosos da amostra.

Avaliada sobre o conjunto de teste inédito (30%), a rede neural obteve os seguintes resultados de generalização:

- **RMSE no Teste:** $0{,}657648$
- **R^2 no Teste:** $0{,}317847$

O resultado obtido pela rede neural evidencia um poder explicativo restrito ($R^2 \approx 0{,}3178$). Esse patamar de desempenho sugere, preliminarmente, que a adição de alta capacidade representativa não-linear não é capaz de extrair padrões determinantes ocultos na base de dados. Dentro do espaço delimitado pelos 11 preditores físico-químicos, a flexibilidade da arquitetura tende apenas a ajustar o modelo à variabilidade estocástica inerente às notas subjetivas atribuídas pelos avaliadores. A hipótese de que o sinal explicativo atrelado à qualidade do vinho é, na realidade, predominantemente linear será devidamente explorada e confirmada no comparativo global de desempenho estruturado na Seção IV.

III. RESULTADOS

As Tabelas VI e VII consolidam as métricas finais obtidas pelos quatro métodos avaliados sobre a porção de 30% dos dados de teste para os vinhos tinto e branco, respectivamente. Estas partições foram mantidas rigorosamente isoladas durante as fases de treinamento e calibração de hiperparâmetros. O desempenho é quantificado através da Raiz do Erro Quadrático Médio (RMSE) e do Coeficiente de Determinação (R^2).

Tabela VI
RESUMO COMPARATIVO DE DESEMPENHO PREDITIVO NO CONJUNTO DE TESTE (VINHO TINTO)

Modelo	RMSE	R^2
Regressão OLS (*Scratch*)	0.6412	0.3515
Lasso (L_1, $\lambda^\star = 0{,}00518$)	0.6417	0.3505
PLS (5 Componentes)	0.6402	0.3536
Rede Neural (MLP)	0.6576	0.3178

A comparação visual direta do erro preditivo e do poder de explicação entre as diferentes metodologias é ilustrada graficamente nas Figuras 5 e 6.

Observa-se empiricamente uma dicotomia de comportamento entre as duas bases de dados. Para o vinho tinto, o modelo de Mínimos Quadrados Parciais (PLS) apresentou o melhor desempenho geral (RMSE $= 0{,}6402$, $R^2 = 0{,}3536$),

Tabela VII
RESUMO COMPARATIVO DE DESEMPENHO PREDITIVO NO CONJUNTO DE TESTE (VINHO BRANCO)

Modelo	**RMSE**	**R^2**
Regressão OLS (*Scratch*)	0.7328	0.2887
Lasso (L_1, $\lambda^* = 0{,}00010$)	0.7352	0.2841
PLS (Componentes Ótimos)	0.7329	0.2886
Rede Neural (MLP)	0.6976	0.3555

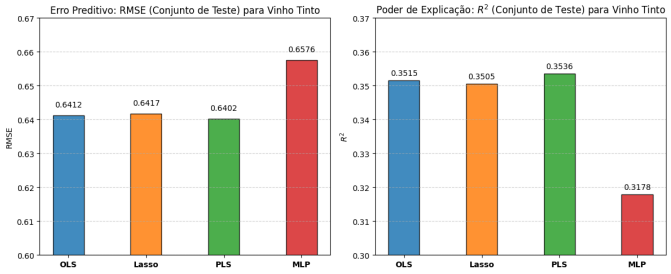


Figura 5. Comparação do desempenho dos modelos preditivos no conjunto de teste para o Vinho Tinto através das métricas RMSE (esquerda) e R^2 (direita).

seguido de perto pelos modelos lineares OLS e Lasso, enquanto a Rede Neural (MLP) obteve o pior ajuste. Em contraste absoluto, a avaliação no vinho branco revelou que a Rede Neural (MLP) superou significativamente todos os métodos lineares, alcançando o menor erro (RMSE $= 0{,}6976$) e a maior variância explicada ($R^2 = 0{,}3555$) da categoria.

IV. DISCUSSÃO

A premissa fundamental desta modelagem foi investigar a viabilidade de substituir a avaliação sensorial subjetiva da qualidade do vinho por estimativas preditivas extraídas puramente de ensaios físico-químicos. Teoricamente, esperava-se que o aumento da complexidade e da flexibilidade dos modelos refletisse em ganhos proporcionais de precisão. O OLS figurava como a linha de base metodológica; o Lasso prometia parcimônia ao eliminar redundâncias; o PLS almejava isolar os vetores latentes de sabor; e a Rede Neural (MLP) visava capturar os padrões não-aditivos complexos do paladar.

Os resultados evidenciam que a natureza matemática do paladar difere drasticamente dependendo do tipo de vinho. A base de dados do vinho tinto exibe um comportamento eminentemente linear. O desempenho superior do PLS (com 5 componentes) em relação ao OLS irrestrito comprova a eficácia da redução de dimensionalidade, filtrando ruídos ortogonais. A estagnação de desempenho no Lasso (RMSE de $0{,}6412$ no OLS para $0{,}6417$ no Lasso) corrobora o princípio da parcimônia: é possível anular grande parte das medições laboratoriais com sacrifício estatisticamente irrisório na precisão preditiva. O fato de a arquitetura MLP perder em generalização para as regressões lineares no vinho tinto atesta que, neste subgrupo, a adição de capacidade não-linear apenas induz o modelo a memorizar o ruído estocástico (sobreajuste).

Em contrapartida, o vinho branco apresenta características físico-químicas subjacentes acentuadamente não-lineares. Os regressores estritamente lineares (OLS, Lasso e PLS) colapsaram num patamar de desempenho inferior (explicando apenas cerca de 28% da variância). A Rede Neural, por outro lado, conseguiu extrair mapeamentos complexos e interações de ordem superior que escapam à formulação aditiva das equações normais, elevando o poder de explicação para $35{,}55\%$ e reduzindo o erro de predição substancialmente em relação ao *baseline*. Isso sugere que o equilíbrio sensorial em vinhos brancos (provavelmente dependente de interações finas entre acidez volátil, açúcares e compostos aromáticos não medidos isoladamente) não obedece a uma simples soma ponderada de atributos.

Apesar da superioridade do MLP no vinho branco e do PLS no vinho tinto, nota-se um limite global no poder explicativo dos algoritmos: em ambos os cenários de melhor caso, os modelos estagnaram em um R^2 em torno de $0{,}35$. Esse teto preditivo transversal evidencia a presença de um forte componente de ruído estocástico — inerente à subjetividade humana nas mesas de degustação — ou a ausência crítica de variáveis organolépticas (como perfil de ésteres e taninos complexos) que não constam nos ensaios laboratoriais de rotina utilizados neste conjunto de dados. Estes achados estão alinhados com investigações recentes sobre a importância preditiva das características físico-químicas em bases de dados desbalanceadas. Por exemplo, em estudos comparativos com algoritmos de aprendizado de máquina aplicados à qualidade do vinho, foi evidenciado que um subconjunto selecionado de atributos (como a quantidade de álcool) tem impacto decisivo na precisão da modelagem, enquanto outros preditores contribuem marginalmente [2].

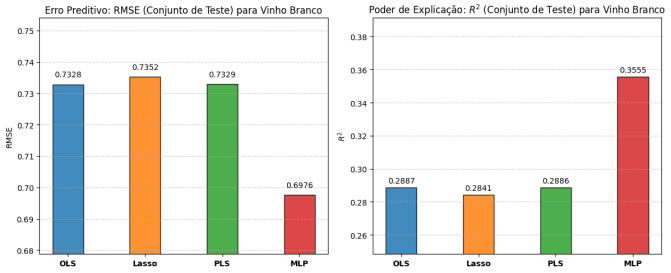


Figura 6. Comparação do desempenho dos modelos preditivos no conjunto de teste para o Vinho Branco através das métricas RMSE (esquerda) e R^2 (direita).

REFERÊNCIAS

[1] E. P. Theisen, Y. S. R. Silva, V. L. Branco, S. Tiburski, e J. D. R. Ozório, "Fatores que influenciam a percepção sensorial de vinhos," *Rev. Bras. Vitic. Enol.*, n. 18, pp. 76–84, 2026.

[2] S. Zaza, M. Atemkeng, e S. Hamlomo, "Wine feature importance and quality prediction: A comparative study of machine learning algorithms with unbalanced data," *arXiv preprint arXiv:2310.01584v1*, 2023.